

QLoRA: Efficient Finetuning of Quantized LLMs

QLoRA: 양자화된 LLM의 효율적인 미세조정

원저자: Tim Dettmers*, Artidoro Pagnoni*, Ari Holtzman, Luke Zettlemoyer (University of Washington, *공동 1저자)

원문: arXiv:2305.14314v1 [cs.LG] (2023-05-23) · 코드: <https://github.com/artidoro/qlora>, <https://github.com/TimDettmers/bitsandbytes>

본 문서는 학습 목적의 한국어 번역본이다. 개념을 나타내는 전문 용어는 「한국어(영어)」 형식으로 병기했으며, 약어 (LoRA, NF4, MMLU 등)는 최초 등장 시 풀어쓰고 이후 약어로 표기한다. 고유명사, 모델명·데이터셋명, 그림·표 라벨, 수식 기호는 영어 원문 그대로 둔다. 그림과 표는 원문 PDF에서 잘라내어 삽입했고, 캡션 번역을 파란 상자로 덧붙였다. 참고문헌(References) 목록은 고유명사 나열이므로 원문을 참조한다.

목차

- 초록 (Abstract)
- 1. 서론 (Introduction)
- 2. 배경 (Background)
- 3. QLoRA 미세조정 (QLoRA Finetuning)
- 4. QLoRA vs. 표준 미세조정 (QLoRA vs. Standard Finetuning)
- 5. QLoRA로 챗봇 최신 기술을 끌어올리기 (Pushing the Chatbot State-of-the-art with QLoRA)
- 6. 정성적 분석 (Qualitative Analysis)
- 7. 관련 연구 (Related Work)
- 8. 한계와 논의 (Limitations and Discussion)
- 9. 광범위한 영향 (Broader Impacts)
- 부록 A-G (Appendix)

초록 (Abstract)

우리는 **QLoRA**를 제안한다. QLoRA는 메모리 사용량을 크게 줄여 **단일 48GB GPU에서 65B 파라미터 모델을 미세조정(finetuning)**하면서도 16비트 완전 미세조정(full finetuning)의 과제 성능을 그대로 유지하는 효율적인 미세조정 기법이다. QLoRA는 고정(frozen)된 4비트 양자화(quantized) 사전학습 언어 모델을 통해 그래디언트를 역전파하여 저랭크 어댑터(Low Rank Adapters, LoRA)를 학습시킨다. 우리가 **Guanaco**라 이름 붙인 최고 성능 모델 계열은 Vicuna 벤치마크에서 이전까지 공개된 모든 모델을 능가하며, 단일 GPU에서 24시간의 미세조정만으로 ChatGPT 성능 수준의 99.3%에 도달한다. QLoRA는 성능을 희생하지 않고 메모리를 절약하기 위한 여러 혁신을 도입한다: (a) 정규분포를 따르는 가중치에 대해 정보이론적으로 최적인 새로운 데이터 타입 **4비트 NormalFloat(NF4)**, (b) 양자화 상수를 다시 양자화하여 평균 메모리 사용량을 줄이는 **이중 양자화(Double Quantization)**, (c) 메모리 스파이크를 관리하는 **페이지드 옵티마이저(Paged Optimizers)**. 우리는 QLoRA로 1,000개가 넘는 모델을 미세조정하여, 8개 지시 데이터셋, 여러 모델 유형(LLaMA, T5), 그리고 일반적인 미세조정으로는 실행이 불가능한 모델 규모(예: 33B, 65B 파라미터 모델)에 걸쳐 지시 따르기(instruction following)와 챗봇 성능을 상세히 분석한다. 그 결과, 작은 고품질 데이터셋에 대한 QLoRA 미세조정은 이전 SoTA보다 작은 모델을

쓰더라도 최고 수준(state-of-the-art)의 결과를 낳는다는 것을 보인다. 또한 인간 평가와 GPT-4 평가에 기반한 챗봇 성능의 상세 분석을 제공하여, GPT-4 평가가 인간 평가의 저렴하고 합리적인 대안임을 보인다. 나아가 현재의 챗봇 벤치마크들이 챗봇의 성능 수준을 정확하게 평가하기에 신뢰할 만하지 않다는 점을 발견한다. 어떤 부분에서 Guanaco가 ChatGPT에 비해 실패하는지를 선별 분석(lemon-picked analysis)으로 보여준다. 우리는 4비트 학습용 CUDA 커널을 포함한 모든 모델과 코드를 공개한다.

1. 서론 (Introduction)

대형 언어 모델(large language models, LLM)의 미세조정은 성능을 개선하고 원하는 행동을 더하거나 원치 않는 행동을 제거하는 매우 효과적인 방법이다. 그러나 매우 큰 모델의 미세조정은 비용이 지나치게 크다. LLaMA 65B 파라미터 모델의 일반적인 16비트 미세조정에는 780GB가 넘는 GPU 메모리가 필요하다. 최근의 양자화 기법들이 LLM의 메모리 사용량을 줄일 수 있지만, 이러한 기법은 추론(inference)에만 작동하며 학습 중에는 무너진다.

우리는 **성능 저하 없이 양자화된 4비트 모델을 미세조정하는 것이 가능함을 처음으로 보인다**. 우리의 방법 QLoRA는 새로운 고정밀 기법으로 사전학습 모델을 4비트로 양자화한 뒤, 양자화된 가중치를 통해 그래디언트를 역전파하는 방식으로 학습 가능한 소량의 저랭크 어댑터(Low-rank Adapter) 가중치를 추가한다.

Model	Size	Elo
GPT-4	-	1348 $\pm$ 1
Guanaco 65B	41 GB	1022 $\pm$ 1
Guanaco 33B	21 GB	992 $\pm$ 1
Vicuna 13B	26 GB	974 $\pm$ 1
ChatGPT	-	966 $\pm$ 1
Guanaco 13B	10 GB	916 $\pm$ 1
Bard	-	902 $\pm$ 1
Guanaco 7B	6 GB	879 $\pm$ 1

Table 1: 10,000회의 무작위 초기 순서에 대해 평균한, 모델 간 경쟁의 Elo 점수. 경기의 승자는 Vicuna 벤치마크의 프롬프트에 대해 어느 응답이 더 나은지를 GPT-4가 판정하여 결정한다. 95% 신뢰구간을 표시($\pm$)했다. GPT-4 다음으로 Guanaco 33B와 65B가 가장 많은 경기에서 이겼으며, Guanaco 13B는 Bard보다 좋은 점수를 얻었다.

QLoRA는 65B 파라미터 모델 미세조정의 평균 메모리 요구량을 780GB 이상의 GPU 메모리에서 48GB 미만으로 줄이면서도, 16비트 완전 미세조정 기준선(baseline) 대비 실행 시간이나 예측 성능을 저하시키지 않는다. 이는 LLM 미세조정의 접근성에서 중대한 전환을 의미한다: 이제 지금까지 공개된 가장 큰 모델들을 단일 GPU에서 미세조정할 수 있다. QLoRA를 사용해 우리는 **Guanaco** 모델 계열을 학습시켰는데, 두 번째로 좋은 모델은 Vicuna 벤치마크에서 ChatGPT 성능 수준의 97.8%에 도달하면서도 단일 소비자용 GPU에서 12시간 이내에 학습 가능하다. 단일 전문가용 GPU에서 24시간을 들이면 가장 큰 모델로 99.3%를 달성하여, Vicuna 벤치마크에서 ChatGPT와의 격차를 사실상 없앤다. 배포 시 가장 작은 Guanaco 모델(7B 파라미터)은 5GB의 메모리만 필요하면서도 Vicuna 벤치마크에서 26GB Alpaca 모델을 20%p 이상 앞선다(Table 6).

QLoRA는 성능 희생 없이 메모리 사용을 줄이도록 설계된 여러 혁신을 도입한다: (1) **4비트 NormalFloat** — 정규 분포 데이터에 대해 정보이론적으로 최적인 양자화 데이터 타입으로, 4비트 정수(Integer)나 4비트 부동소수

(Float)보다 더 나은 경험적 결과를 낳는다. (2) **이중 양자화(Double Quantization)** — 양자화 상수를 다시 양자화하는 방법으로, 파라미터당 평균 약 0.37비트(65B 모델 기준 약 3GB)를 절약한다. (3) **페이지드 옵티마이저(Paged Optimizers)** — NVIDIA 통합 메모리(unified memory)를 사용하여, 긴 시퀀스 길이의 미니배치를 처리할 때 발생하는 그래디언트 체크포인팅의 메모리 스파이크를 피한다. 우리는 이 기여들을 모든 네트워크 계층에 어댑터를 두는, 더 잘 조율된 LoRA 접근법으로 결합하여 이전 연구에서 보였던 정확도 절충(tradeoff)을 거의 모두 회피한다.

QLoRA의 효율성 덕분에, 일반적인 미세조정으로는 메모리 오버헤드 때문에 불가능했을 모델 규모에서 지시 미세조정(instruction finetuning)과 챗봇 성능을 깊이 있게 연구할 수 있다. 우리는 여러 지시 튜닝 데이터셋, 모델 아키텍처, 80M~65B 파라미터 크기에 걸쳐 1,000개 이상의 모델을 학습시켰다. QLoRA가 16비트 성능을 회복함을 보이고 (§ 4) 최신 수준의 챗봇 Guanaco를 학습시킨 것 (§ 5)에 더해, 학습된 모델들의 경향도 분석한다. 첫째, 데이터 품질이 데이터셋 크기보다 훨씬 중요하다는 것을 발견했다. 예컨대 9천 샘플 데이터셋(OASST1)이 45만 샘플 데이터셋(FLAN v2, 서브샘플링)을 챗봇 성능에서 능가했는데, 두 데이터셋 모두 지시 따르기 일반화를 목표로 한 것이다. 둘째, 강한 MMLU(Massive Multitask Language Understanding) 벤치마크 성능이 강한 Vicuna 챗봇 벤치마크 성능을 의미하지 않으며 그 역도 성립하지 않음을 보인다. 즉, 주어진 과제에 대해서는 데이터셋의 적합성이 크기보다 더 중요하다.

나아가 인간 평가자와 GPT-4를 모두 사용하는 챗봇 성능의 광범위한 분석을 제공한다. 우리는 주어진 프롬프트에 대해 최고의 응답을 만들기 위해 모델들이 경기(match)에서 맞붙는 토너먼트 방식 벤치마킹을 사용한다. 경기의 승자는 GPT-4 또는 인간 주석자가 판정한다. 토너먼트 결과는 Elo 점수로 집계되어 챗봇 성능 순위를 결정한다. GPT-4와 인간 평가는 토너먼트에서의 모델 성능 순위에 대체로 동의하지만, 강하게 불일치하는 사례들도 있음을 발견했다. 따라서 모델 기반 평가가 인간 주석의 저렴한 대안을 제공하는 한편 불확실성 또한 있다는 점을 강조한다.

우리는 챗봇 벤치마크 결과를 Guanaco 모델의 정성적 분석으로 보강한다. 이 분석은 정량적 벤치마크가 포착하지 못한 성공과 실패 사례들을 조명한다.

우리는 추가 연구를 돕기 위해 인간 및 GPT-4 주석이 달린 모든 모델 생성 결과를 공개한다. 코드베이스와 CUDA 커널을 오픈소스화하고 우리의 방법을 Hugging Face transformers 스택에 통합하여 모두가 쉽게 접근할 수 있게 했다. 7/13/33/65B 크기 모델에 대해 8개의 서로 다른 지시 따르기 데이터셋으로 학습한 어댑터 모음, 총 32개의 오픈소스 미세조정 모델을 공개한다.




Figure 1: 서로 다른 미세조정 방법과 그 메모리 요구량. QLoRA는 트랜스포머 모델을 4비트 정밀도로 양자화하고 메모리 스파이크를 페이지드 옵티마이저로 처리함으로써 LoRA를 개선한다.

2. 배경 (Background)

블록 단위 k-비트 양자화 (Block-wise k-bit Quantization)

양자화(quantization)는 더 많은 정보를 담는 표현의 입력을 더 적은 정보를 담는 표현으로 이산화하는 과정이다. 흔히 더 많은 비트의 데이터 타입을 더 적은 비트로 변환하는 것을 뜻하며, 예를 들어 32비트 부동소수를 8비트 정수로 바꾸는 식이다. 저비트 데이터 타입의 범위 전체가 사용되도록, 보통 입력 요소들의 절대 최댓값(absolute maximum)으로 정규화하여 입력 데이터 타입을 목표 데이터 타입의 범위로 재조정(rescale)한다. 입력 요소들은 대개 텐서 형태로 구조화되어 있다. 예를 들어 32비트 부동소수(FP32) 텐서를 범위 $[-127, 127]$ 의 Int8 텐서로 양자화하면:

$$X^{\text{Int8}} = \text{round}(127 / \text{absmax}(X^{\text{FP32}}) \cdot X^{\text{FP32}}) = \text{round}(c^{\text{FP32}} \cdot X^{\text{FP32}}) \quad (1)$$

여기서 c 는 **양자화 상수(quantization constant)** 또는 양자화 스케일(quantization scale)이다. 역양자화(dequantization)는 그 역이다:

$$\text{dequant}(c^{\text{FP32}}, X^{\text{Int8}}) = X^{\text{Int8}} / c^{\text{FP32}} = X^{\text{FP32}} \quad (2)$$

이 접근법의 문제는, 입력 텐서에 큰 크기의 값(즉, 이상치, outlier)이 나타나면 일부 양자화 구간(bin) — 특정 비트 조합 — 이 거의 또는 전혀 활용되지 못한다는 점이다. 이상치 문제를 방지하기 위한 일반적인 접근은 입력 텐서를 독립적으로 양자화되는 블록들로 쪼개어 각 블록이 자체 양자화 상수 c 를 갖게 하는 것이다. 이는 다음과 같이 정식화할 수 있다: 입력 텐서 $X \in \mathbb{R}^{b \times h}$ 를 평탄화(flatten)한 뒤 선형 구간을 $n = (b \times h)/B$ 개의 블록으로 잘라, 크기 B 의 연속 블록 n 개로 쪼갬다. 이 블록들을 식 (1)로 독립적으로 양자화하여, 양자화된 텐서와 n 개의 양자화 상수 c_i 를 만든다.

저랭크 어댑터 (Low-rank Adapters)

저랭크 어댑터(LoRA) 미세조정은 고정된 채 유지되는 전체 모델 파라미터는 갱신하지 않고, 어댑터(adapter)라 불리는 소량의 학습 가능한 파라미터를 사용하여 메모리 요구량을 줄이는 방법이다. 확률적 경사 하강 중의 그래디언트는 고정된 사전학습 모델 가중치를 지나 어댑터로 전달되며, 어댑터는 손실 함수를 최적화하도록 갱신된다. LoRA는 선형 투영(linear projection)을 추가적인 인수분해 투영으로 보강한다. $X \in \mathbb{R}^{b \times h}$, $W \in \mathbb{R}^{h \times o}$ 인 투영 $XW = Y$ 가 주어질 때 LoRA는 다음을 계산한다:

$$Y = XW + sXL_1L_2 \quad (3)$$

여기서 $L_1 \in \mathbb{R}^{h \times r}$, $L_2 \in \mathbb{R}^{r \times o}$ 이고 s 는 스칼라다.

파라미터 효율적 미세조정기의 메모리 요구량 (Memory Requirement of Parameter-Efficient Finetuning)

중요한 논점 하나는 학습 중 LoRA의 메모리 요구량이며, 이는 사용되는 어댑터의 개수와 크기 양쪽 측면에서 그렇다. LoRA의 메모리 사용량은 매우 작으므로, 전체 사용 메모리를 크게 늘리지 않고도 더 많은 어댑터를 사용해 성능을 개선할 수 있다. LoRA는 파라미터 효율적 미세조정(Parameter Efficient Finetuning, PEFT) 방법으로 설계되

었지만, LLM 미세조정의 메모리 사용량 대부분은 학습되는 LoRA 파라미터가 아니라 활성화 값 그래디언트(activation gradient)에서 나온다. 배치 크기 1로 FLAN v2에서 학습되는 7B LLaMA 모델에서, 흔히 쓰이는 원본 모델 가중치의 0.2%에 해당하는 LoRA 가중치를 쓸 때, LoRA 입력 그래디언트는 567MB의 메모리를 차지하는 반면 LoRA 파라미터 자체는 26MB만 차지한다. 그래디언트 체크포인팅을 적용하면 입력 그래디언트는 시퀀스당 평균 18MB로 줄어드는데, 그래도 모든 LoRA 가중치를 합친 것보다 메모리를 더 쓴다. 비교하자면 4비트 기반 모델(base model)은 5,048MB의 메모리를 소비한다. 이는 그래디언트 체크포인팅이 중요하다는 점, 그리고 LoRA 파라미터 양을 공격적으로 줄여도 메모리 이득은 미미하다는 점을 보여준다. 즉 전체 학습 메모리 사용량을 크게 늘리지 않고 더 많은 어댑터를 사용할 수 있다는 뜻이다(상세 내역은 부록 G 참조). 뒤에서 논의하듯, 이는 완전한 16비트 정밀도 성능을 회복하는 데 결정적이다.

3. QLoRA 미세조정 (QLoRA Finetuning)

QLoRA는 우리가 제안하는 두 가지 기법 — 4비트 NormalFloat(NF4) 양자화와 이중 양자화 — 을 통해 고충실도(high-fidelity) 4비트 미세조정을 달성한다. 추가로 페이지드 옵티마이저를 도입하여, 그래디언트 체크포인팅 중의 메모리 스파이크가 메모리 부족(out-of-memory) 오류를 일으키는 것을 방지한다. 이러한 오류는 전통적으로 대형 모델의 단일 머신 미세조정을 어렵게 만들어 왔다.

QLoRA는 하나의 저장밀 저장 데이터 타입(우리의 경우 보통 4비트)과 하나의 계산 데이터 타입(보통 BFloat16)을 갖는다. 실제로는 QLoRA 가중치 텐서가 사용될 때마다 그 텐서를 BFloat16으로 역양자화한 다음 16비트로 행렬 곱셈을 수행한다는 뜻이다.

이제 QLoRA의 구성 요소들을 논의한 뒤 QLoRA의 형식적 정의를 제시한다.

4비트 NormalFloat 양자화 (4-bit NormalFloat Quantization)

NormalFloat(NF) 데이터 타입은 분위수 양자화(Quantile Quantization)에 기반한다. 분위수 양자화는 각 양자화 구간에 입력 텐서로부터 동일한 개수의 값이 배정되도록 보장하는, 정보이론적으로 최적인 데이터 타입이다. 분위수 양자화는 경험적 누적분포함수(empirical cumulative distribution function)를 통해 입력 텐서의 분위수를 추정하는 방식으로 작동한다.

분위수 양자화의 주된 한계는 분위수 추정 과정의 비용이 크다는 점이다. 그래서 SRAM quantiles 같은 빠른 분위수 근사 알고리즘이 추정에 사용된다. 이러한 분위수 추정 알고리즘의 근사적 성격 때문에, 이 데이터 타입은 이상치에 대해 큰 양자화 오차를 가지는데, 이상치야말로 종종 가장 중요한 값들이다.

입력 텐서가 양자화 상수를 제외하면 고정된 분포에서 나오는 경우에는, 값비싼 분위수 추정과 근사 오차를 피할 수 있다. 그런 경우 입력 텐서들은 같은 분위수를 가지므로 정확한 분위수 추정이 계산적으로 가능해진다.

사전학습된 신경망 가중치는 보통 표준편차 σ 를 갖는 0 중심의 정규분포를 따르므로(부록 F 참조), σ 를 스케일링하여 분포가 우리 데이터 타입의 범위에 정확히 들어맞도록 하면 모든 가중치를 하나의 고정된 분포로 변환할 수 있다. 우리 데이터 타입의 범위는 임의로 $[-1, 1]$ 로 정한다. 따라서 데이터 타입의 분위수와 신경망 가중치 모두 이 범위로 정규화되어야 한다.

범위 $[-1, 1]$ 안에서 임의의 표준편차 σ 를 갖는 0 평균 정규분포에 대해 정보이론적으로 최적인 데이터 타입은 다음과 같이 계산된다: (1) 이론적 $N(0, 1)$ 분포의 2^{k+1} 개 분위수를 추정하여 정규분포용 k -비트 분위수 양자화 데이터 타입을 얻고, (2) 이 데이터 타입의 값들을 $[-1, 1]$ 범위로 정규화한 뒤, (3) 절대 최댓값 재조정을 통해 입력 가중치 텐서를 $[-1, 1]$ 범위로 정규화하여 양자화한다.

가중치 범위와 데이터 타입 범위가 일치하면 평소처럼 양자화할 수 있다. 단계 (3)은 가중치 텐서의 표준편차를 k-비트 데이터 타입의 표준편차에 맞춰 재조정하는 것과 동등하다. 더 형식적으로, 데이터 타입의 2^k 개 값 q_i 를 다음과 같이 추정한다:

$$q_i = \frac{1}{2} (Q_X(i/(2^{k+1})) + Q_X((i+1)/(2^{k+1}))) \quad (4)$$

여기서 $Q_X(\cdot)$ 는 표준 정규분포 $N(0, 1)$ 의 분위수 함수(quantile function)다. 대칭적 k-비트 양자화의 문제는 이 접근법이 0의 정확한 표현을 갖지 못한다는 점인데, 0의 정확한 표현은 패딩(padding)이나 기타 0 값 요소들을 오차 없이 양자화하는 데 중요한 속성이다. 0의 이산적 영점(zeropoint)을 보장하고 k-비트 데이터 타입의 2^k 개 비트를 전부 사용하기 위해, 우리는 두 범위의 분위수 q_i — 음수 부분에 대해 2^{k-1} 개, 양수 부분에 대해 $2^{k-1}+1$ 개 — 를 추정한 뒤 이 q_i 집합들을 합치고 두 집합에 모두 나타나는 0 하나를 제거함으로써 비대칭 데이터 타입을 만든다. 각 양자화 구간에 동일한 기대 개수의 값이 들어가는 이 데이터 타입을, 0 중심 정규분포 데이터에 대해 정보이론적으로 최적이므로 **k-비트 NormalFloat(NFk)**라 부른다. 이 데이터 타입의 정확한 값들은 부록 E에 있다.

이중 양자화 (Double Quantization)

우리는 추가 메모리 절약을 위해 양자화 상수를 다시 양자화하는 과정인 이중 양자화(Double Quantization, DQ)를 도입한다. 정밀한 4비트 양자화에는 작은 블록 크기가 필요하지만, 이는 상당한 메모리 오버헤드도 수반한다. 예를 들어 W에 32비트 상수와 블록 크기 64를 쓰면 양자화 상수가 파라미터당 평균 $32/64 = 0.5$ 비트를 추가한다. 이중 양자화는 양자화 상수의 메모리 사용량을 줄이는 데 도움이 된다.

더 구체적으로, 이중 양자화는 1차 양자화의 양자화 상수 c_2^{FP32} 를 2차 양자화의 입력으로 취급한다. 이 2차 단계는 양자화된 양자화 상수 c_2^{FP8} 과 2차 수준의 양자화 상수 c_1^{FP32} 를 산출한다. 2차 양자화에는 8비트 부동소수와 블록 크기 256을 사용하는데, 8비트 양자화에서는 성능 저하가 관찰되지 않기 때문이다. c_2^{FP32} 는 양수이므로, 양자화 전에 c_2 에서 평균을 빼서 값들을 0 중심으로 만들고 대칭 양자화를 활용한다. 평균적으로 블록 크기 64에서 이 양자화는 파라미터당 메모리 사용량을 $32/64 = 0.5$ 비트에서 $8/64 + 32/(64 \cdot 256) = 0.127$ 비트로, 파라미터당 0.373비트 만큼 줄인다.

페이지드 옵티마이저 (Paged Optimizers)

NVIDIA 통합 메모리 기능을 사용한다. 이 기능은 GPU가 간헐적으로 메모리 부족에 빠지는 상황에서 오류 없는 GPU 처리를 위해 CPU와 GPU 간 페이지 단위 자동 전송을 수행한다. CPU RAM과 디스크 사이의 일반적인 메모리 페이지처럼 작동한다. 우리는 이 기능으로 옵티마이저 상태(optimizer state)에 페이지드 메모리를 할당하여, GPU가 메모리 부족이 되면 자동으로 CPU RAM으로 내보내고 옵티마이저 갱신 단계에서 메모리가 필요해지면 GPU 메모리로 다시 페이지징한다.

QLoRA

위에서 설명한 구성 요소들을 사용하여, 양자화된 기반 모델의 단일 선형 계층과 단일 LoRA 어댑터에 대한 QLoRA를 다음과 같이 정의한다:

$$Y^{BF16} = X^{BF16} \text{doubleDequant}(c_1^{FP32}, c_2^{k\text{-bit}}, W^{NF4}) + X^{BF16} L_1^{BF16} L_2^{BF16} \quad (5)$$

여기서 $\text{doubleDequant}(\cdot)$ 는 다음과 같이 정의된다:

$$\text{doubleDequant}(c_1^{FP32}, c_2^{k\text{-bit}}, W^{k\text{-bit}}) = \text{dequant}(\text{dequant}(c_1^{FP32}, c_2^{k\text{-bit}}), W^{4\text{bit}}) = W^{BF16} \quad (6)$$

W 에는 NF4를, c_2 에는 FP8을 사용한다. 더 높은 양자화 정밀도를 위해 W 의 블록 크기는 64로, 메모리 절약을 위해 c_2 의 블록 크기는 256으로 한다.

파라미터 갱신에는 어댑터 가중치에 대한 오차의 그래디언트 $\partial E / \partial L_i$ 만 필요하고 4비트 가중치에 대한 $\partial E / \partial W$ 는 필요 없다. 다만 $\partial E / \partial L_i$ 의 계산은 $\partial X / \partial W$ 의 계산을 수반하는데, 이는 식 (5)를 거쳐 저장 타입 W^{NF4} 에서 계산 타입 W^{BF16} 으로 역양자화하여 BFloat16 정밀도로 미분 $\partial X / \partial W$ 를 계산하는 방식으로 진행된다.

요약하면, QLoRA는 하나의 저장 데이터 타입(보통 4비트 NormalFloat)과 하나의 계산 데이터 타입(16비트 BrainFloat)을 갖는다. 순전파와 역전파를 수행하기 위해 저장 데이터 타입을 계산 데이터 타입으로 역양자화하지만, 가중치 그래디언트는 16비트 BrainFloat을 쓰는 LoRA 파라미터에 대해서만 계산한다.

4. QLoRA vs. 표준 미세조정 (QLoRA vs. Standard Finetuning)

지금까지 QLoRA가 어떻게 작동하는지, 그리고 모델 미세조정에 필요한 메모리를 어떻게 크게 줄일 수 있는지 논의했다. 이제 핵심 질문은 QLoRA가 완전 모델 미세조정만큼 잘 수행될 수 있는가이다. 나아가 표준 Float4 대비 NormalFloat4의 영향 등 QLoRA의 구성 요소들도 분석하고자 한다. 아래 절들에서 이 질문들에 답하기 위한 실험을 다룬다.

실험 설정 (Experimental setup)

세 가지 아키텍처(인코더, 인코더-디코더, 디코더 전용)를 고려하며, 최대 3B 모델에 대해 QLoRA를 16비트 어댑터 미세조정 및 완전 미세조정과 비교한다. 평가는 RoBERTa-large를 사용한 GLUE, T5를 사용한 Super-NaturalInstructions(TKInstruct), 그리고 LLaMA를 Flan v2와 Alpaca로 미세조정된 후의 5-shot MMLU를 포함한다. 추가로 다른 4비트 데이터 타입 대비 NF4의 이점을 연구하기 위해, Dettmers와 Zettlemoyer의 설정을 사용하여 서로 다른 모델(OPT, LLaMA, BLOOM, Pythia)의 125M~13B 크기에 걸쳐 양자화 후 제로샷 정확도와 퍼플렉시티(perplexity)를 측정한다. 각 설정의 세부 사항은 결과를 읽기 쉽도록 해당 결과 절에서 제공하며, 전체 세부 사항은 부록 A에 있다.

33B/65B QLoRA 튜닝을 단일 24/48GB GPU에서 수행하는 데 페이지드 옵티마이저가 필수적이긴 하지만, 페이지징이 긴 시퀀스 길이의 미니배치를 처리할 때만 드물게 발생하므로 페이지드 옵티마이저에 대한 엄밀한 측정치는 제공하지 않는다. 다만 48GB GPU에서 65B 모델에 대한 페이지드 옵티마이저의 실행 시간을 분석한 결과, 배치 크기 16에서 페이지드 옵티마이저는 일반 옵티마이저와 동일한 학습 속도를 제공했다. 향후 연구에서는 어떤 상황에서 페이지징 과정으로 인한 속도 저하가 일어나는지 측정하고 특성화해야 할 것이다.




Figure 2: Alpaca 데이터셋에서 LLaMA 7B 모델들의 RougeL. 각 점은 서로 다른 랜덤 시드로 실행한 결과다. 우리는 Stanford Alpaca의 완전 미세조정 기본 하이퍼파라미터를 개선하여 비교를 위한 강한 16비트 기준선을 구성했다. 모든 트랜스포머 계층에 LoRA를 적용하는 것이 16비트 성능에 맞추는 데 결정적이다.

기본 LoRA 하이퍼파라미터는 16비트 성능에 못 미친다 (Default LoRA hyperparameters do not match 16-bit performance)

쿼리와 값 어텐션 투영 행렬에 LoRA를 적용하는 표준 관행을 따르면, 큰 기반 모델에서 완전 미세조정 성능을 재현할 수 없다. Figure 2의 Alpaca에 대한 LLaMA 7B 미세조정에서 보듯, 가장 결정적인 LoRA 하이퍼파라미터는 총 몇 개의 LoRA 어댑터를 사용하는가이며, 완전 미세조정 성능에 맞추려면 트랜스포머 블록의 모든 선형 계층에 LoRA가 필요하다는 것을 발견했다. 투영 차원 r 같은 다른 LoRA 하이퍼파라미터는 성능에 영향을 주지 않는다(부록 A 참조).

마찬가지로, 완전 미세조정 기준선의 기본 하이퍼파라미터도 충분히 튜닝되어 있지 않음을 발견했다. 학습률 $1e-6 \sim 5e-5$ 와 배치 크기 $8 \sim 128$ 에 걸친 하이퍼파라미터 탐색으로 견고한 기준선을 찾았다. Alpaca에 대한 7B LLaMA 미세조정 결과는 Figure 2에 있다.




Figure 3: 서로 다른 4비트 데이터 타입의 LLaMA 모델로 측정한 Winogrande, HellaSwag, PiQA, Arc-Easy, Arc-Challenge의 평균 제로샷 정확도. NormalFloat 데이터 타입은 일반 4비트 Float 대비 비트당 정확도 이득을 크게 개선한다. 이중 양자화(DQ)는 미미한 이득만 주지만, 특정 크기의 모델(33B/65B)을 특정 GPU(24/48GB)에 맞춰 넣을 수 있도록 메모리 사용량을 더 세밀하게 제어할 수 있게 한다.

4비트 NormalFloat이 4비트 부동소수보다 더 나은 성능을 낸다 (4-bit NormalFloat yields better performance than 4-bit Floating Point)

4비트 NormalFloat(NF4) 데이터 타입은 정보이론적으로 최적이지만, 이 속성이 경험적 이점으로 이어지는지는 확인이 필요하다. 우리는 Dettmers와 Zettlemoyer의 설정을 따라, 다양한 크기(125M~65B)의 양자화된 LLM(OPT, BLOOM, Pythia, LLaMA)을 서로 다른 데이터 타입으로 언어 모델링과 제로샷 과제 집합에서 평가했다. Figure 3과 Table 2에서 NF4가 FP4와 Int4 대비 성능을 크게 개선하고, 이중 양자화가 성능 저하 없이 메모리 사용량을 줄인다는 것을 볼 수 있다.

Dataset Model	GLUE (Acc.)	Super-NaturalInstructions (RougeL)				
	RoBERTa-large	T5-80M	T5-250M	T5-780M	T5-3B	T5-11B
BF16	88.6	40.1	42.1	48.0	54.3	62.0
BF16 replication	88.6	40.0	42.2	47.3	54.9	-
LoRA BF16	88.8	40.5	42.6	47.1	55.4	60.7
QLoRA Int8	88.8	40.4	42.9	45.4	56.5	60.7
QLoRA FP4	88.6	40.3	42.4	47.5	55.6	60.9
QLoRA NF4 + DQ	-	40.4	42.7	47.7	55.3	60.9

Table 3: GLUE와 Super-NaturalInstructions에서 16비트 BrainFloat(BF16), 8비트 정수(Int8), 4비트 Float(FP4), 4비트 NormalFloat(NF4)을 비교한 실험. QLoRA는 16비트 LoRA와 완전 미세조정을 재현한다.

k-비트 QLoRA는 16비트 완전 미세조정과 16비트 LoRA 성능에 필적한다 (k-bit QLoRA matches 16-bit full finetuning and 16-bit LoRA performance)

최근 연구들은 추론을 위한 4비트 양자화가 가능하지만 16비트 대비 성능 저하를 낳는다는 것을 확립했다. 이는 잃어버린 성능을 4비트 어댑터 미세조정으로 회복할 수 있는가라는 중대한 질문을 제기한다. 우리는 이를 두 가지 설정에서 시험한다.

Data type	Mean PPL
Int4	34.34
Float4 (E2M1)	31.07
Float4 (E3M0)	29.48
NFloat4 + DQ	27.41

Table 2: 125M~13B의 OPT, BLOOM, LLaMA, Pythia 모델에 대한 데이터 타입별 Pile Common Crawl 평균 퍼플렉시티.

첫 번째 설정은 125M~3B 파라미터 크기의 RoBERTa와 T5 모델을 GLUE와 Super-NaturalInstructions 데이터셋에서 완전 16비트 미세조정과 비교하는 데 초점을 둔다. 결과는 Table 3에 있다. 두 데이터셋 모두에서 16비트, 8비트, 4비트 어댑터 방법들이 완전 미세조정된 16비트 기준선의 성능을 재현하는 것을 관찰했다. 이는 부정밀한 양자화로 잃어버린 성능이 양자화 후 어댑터 미세조정을 통해 완전히 회복될 수 있음을 시사한다.

두 번째 설정에서는, 11B 파라미터 이상 모델의 완전 미세조정에는 고용량 메모리 GPU 서버 한 대 이상이 필요하므로, 4비트 QLoRA가 7B~65B 파라미터 규모에서 16비트 LoRA에 필적할 수 있는지를 계속 시험한다. 이를 위해 LLaMA 7B부터 65B까지를 두 지시 따르기 데이터셋 Alpaca와 FLAN v2로 미세조정하고 MMLU 벤치마크의 5-shot 정확도로 평가한다. 결과는 Table 4에 있으며, 이중 양자화를 적용한 NF4가 16비트 LoRA의 MMLU 성능을 완전히 회복함을 볼 수 있다. 아울러 FP4를 쓴 QLoRA는 16비트 BrainFloat LoRA 기준선보다 약 1%p 뒤쳐진다는 점도 확인했다. 이는 (1) NF4를 쓴 QLoRA가 16비트 완전 미세조정과 16비트 LoRA 미세조정 성능을 모두 재현하며, (2) 양자화 정밀도 면에서 NF4가 FP4보다 우수하다는 우리의 두 발견을 뒷받침한다.

LLaMA Size Dataset	Mean 5-shot MMLU Accuracy								Mean
	7B		13B		33B		65B		
	Alpaca	FLAN v2	Alpaca	FLAN v2	Alpaca	FLAN v2	Alpaca	FLAN v2	
BFloat16	38.4	45.6	47.2	50.6	57.7	60.5	61.8	62.5	53.0
Float4	37.2	44.0	47.3	50.0	55.9	58.5	61.3	63.3	52.2
NFloat4 + DQ	39.0	44.5	47.5	50.7	57.3	59.2	61.8	63.9	53.1

Table 4: Alpaca와 FLAN v2에서 어댑터로 미세조정된 LLaMA 7-65B 모델의 데이터 타입별 평균 5-shot MMLU 시험 정확도. 전반적으로 이중 양자화(DQ)를 적용한 NF4는 BFLOAT16 성능에 필적하는 반면, FP4는 둘 모두에 일관되게 1%p 뒤쳐진다.

요약 (Summary)

우리의 결과는 NF4 데이터 타입을 쓴 4비트 QLoRA가 잘 확립된 평가 설정을 갖춘 학술 벤치마크에서 16비트 완전 미세조정과 16비트 LoRA 미세조정 성능에 필적함을 일관되게 보여준다. 또한 NF4가 FP4보다 효과적이며 이중 양자화가 성능을 저하시키지 않음을 보였다. 종합하면 이는 4비트 QLoRA 튜닝이 16비트 방법에 필적하는 결과를 신뢰성 있게 낳는다는 설득력 있는 증거를 이룬다.

양자화에 대한 이전 연구와 마찬가지로, 우리의 MMLU와 Elo 결과는 주어진 미세조정 및 추론 자원 예산 하에서는 기반 모델의 파라미터 수를 늘리고 정밀도를 낮추는 것이 유리함을 시사한다. 이는 QLoRA가 주는 효율성 이점의 중요성을 부각한다. 4비트 미세조정 실험에서 완전 미세조정 대비 성능 저하를 관찰하지 못했으므로, QLoRA 튜닝의 성능-정밀도 절충점이 정확히 어디에 있는가라는 질문이 제기되며, 이는 향후 연구로 남긴다.

이제 완전한 16비트 미세조정으로는 학술 연구 하드웨어에서 탐구가 불가능했을 규모의 지시 튜닝을 조사한다.

5. QLoRA로 챗봇 최신 기술을 끌어올리기 (Pushing the Chatbot State-of-the-art with QLoRA)

4비트 QLoRA가 규모, 과제, 데이터셋 전반에서 16비트 성능에 필적함을 확립했으므로, 연구용으로 이용 가능한 가장 큰 오픈소스 언어 모델까지 지시 미세조정을 심층 연구한다. 이 모델들의 지시 미세조정 성능을 평가하기 위해, 까다로운 자연어 이해 벤치마크(MMLU)에서 평가하고 실세계 챗봇 성능 평가를 위한 새로운 방법들을 개발한다.

5.1 실험 설정 (Experimental setup)

실험 설정의 개요를 설명하며, 전체 세부 사항은 부록 B에 있다.

데이터 (Data)

우리가 아는 한 최근 지시 따르기 데이터셋들에 대한 포괄적 연구가 없으므로, 최근의 8개 데이터셋을 선정한다. 크라우드소싱으로 얻은 데이터셋(OASST1, HH-RLHF), 지시 튜닝된 모델로부터의 증류(distillation)로 얻은 데이터셋(Alpaca, Self-Instruct, Unnatural Instructions), 말뭉치 집적(FLAN v2), 그리고 혼합형(Chip2, Longform)을 포함한다. 이 데이터셋들은 서로 다른 언어, 데이터 크기, 라이선스를 아우른다.

학습 설정 (Training Setup)

서로 다른 학습 목표에서 오는 교란 효과를 피하기 위해, 서로 다른 응답에 대한 인간 판단이 포함된 데이터셋에서도 강화학습 없이 교차 엔트로피 손실(지도학습)로 QLoRA 미세조정을 수행한다. 지시와 응답이 명확히 구분되는 데이터셋에서는 응답에 대해서만 미세조정한다(어블레이션은 부록 B 참조). OASST1과 HH-RLHF에는 여러 응답이 존재한다. 이때는 대화 트리의 각 수준에서 최상위 응답을 선택하고, 지시를 포함한 선택된 대화 전체에 대해 미세조정한다. 모든 실험에서 이중 양자화를 적용한 NF4 QLoRA와 페이지드 옵티마이저를 사용하여 그래디언트 체크포인팅 중 메모리 스파이크를 방지한다. 13B와 33B LLaMA 모델에 대해 소규모 하이퍼파라미터 탐색을 수행했으며, 학습률과 배치 크기를 제외하면 7B에서 찾은 모든 하이퍼파라미터 설정(에폭 수 포함)이 일반화됨을 발견했다. 33B와 65B에서는 학습률을 절반으로 줄이고 배치 크기를 두 배로 늘렸다.

기준선 (Baselines)

우리 모델을 연구용(Vicuna, Open Assistant) 및 상용(GPT-4, GPT-3.5-turbo, Bard) 챗봇 시스템과 비교한다. Open Assistant 모델은 우리가 실험하는 것과 같은 OASST1 데이터셋으로 인간 피드백 강화학습(RLHF)을 통해 미세조정된 LLaMA 33B 모델이다. Vicuna는 ShareGPT에서 나온 독점적인 사용자 공유 대화로 LLaMA 13B를 완전 미세조정된 것으로, OpenAI GPT 모델들로부터의 증류 결과물이라 할 수 있다.

5.2 평가 (Evaluation)

일반적인 관행을 따라 MMLU(Massively Multitask Language Understanding) 벤치마크로 다양한 언어 이해 과제에 대한 성능을 측정한다. 이는 초등 수학, 미국사, 컴퓨터과학, 법 등 57개 과제를 아우르는 객관식 벤치마크다. 5-shot 시험 정확도를 보고한다.

Dataset	7B	13B	33B	65B
LLaMA no tuning	35.1	46.9	57.8	63.4
Self-Instruct	36.4	33.3	53.0	56.7
Longform	32.1	43.2	56.6	59.7
Chip2	34.5	41.6	53.6	59.8
HH-RLHF	34.9	44.6	55.8	60.1
Unnatural Instruct	41.9	48.1	57.3	61.3
Guanaco (OASST1)	36.6	46.4	57.0	62.2
Alpaca	38.8	47.8	57.3	62.5
FLAN v2	44.5	51.4	59.2	63.9

Table 5: 해당 데이터셋으로 QLoRA 미세조정된 서로 다른 크기의 LLaMA에 대한 MMLU 5-shot 시험 결과.

또한 자동 평가와 인간 평가 양쪽으로 생성 언어 능력을 시험한다. 이 두 번째 평가는 인간이 선별한 질의에 의존하며 모델 응답의 품질을 측정하는 것을 목표로 한다. 이는 챗봇 모델 성능에 더 현실적인 시험대이고 인기를 얻고 있지만, 문헌에 공통으로 인정되는 프로토콜은 없다. 아래에 우리가 제안하는 설정을 기술하며, 모든 경우에 $p = 0.9$ 의 뉴클리어스 샘플링(nucleus sampling)과 온도(temperature) 0.7을 사용한다.

벤치마크 데이터 (Benchmark Data)

선별된 두 질의(질문) 데이터셋, 즉 Vicuna 프롬프트와 OASST1 검증 데이터셋에서 평가한다. Vicuna 프롬프트는 다양한 범주의 80개 프롬프트 집합으로, 수정 없이 그대로 사용한다. OASST1 데이터셋은 사용자와 어시스턴트 간 다중 턴 대화의 다국어 클라우드소싱 모음이다. 검증 데이터셋의 모든 사용자 메시지를 질의로 선택하고 이전 턴들을 프롬프트에 포함한다. 이 절차로 953개의 고유한 사용자 질의를 얻는다. 이 두 데이터셋을 각각 Vicuna 벤치마크와 OA 벤치마크라 부른다.

자동 평가 (Automated Evaluation)

먼저 Chiang 등이 도입한 평가 프로토콜에 기반하여, Vicuna 벤치마크에서 ChatGPT(GPT-3.5 Turbo) 대비 여러 시스템의 성능을 GPT-4로 평가한다. 질의와 함께 ChatGPT의 응답과 대상 모델의 응답이 주어지면, GPT-4는 두 응답에 10점 만점 점수를 매기고 설명을 제공하도록 프롬프트된다. 모델의 전체 성능은 ChatGPT가 얻은 점수에 대한 백분율로 계산된다. 모델이 ChatGPT보다 더 높은 절대 점수를 받으면 이 상대 점수는 100%를 넘을 수 있다. 우리는 GPT-4가 프롬프트에서 먼저 등장하는 응답의 점수를 높이는 상당한 순서 효과(ordering effect)를 발견했다. 이러한 효과를 통제하기 위해 두 순서 모두에 대한 평균 점수를 보고할 것을 권장한다.

다음으로 시스템 출력 간 직접 비교로 성능을 측정한다. 무승부를 허용하는 3-클래스 라벨링 문제로 평가 방식을 단순화한다. GPT-4에 최고의 응답을 고르거나 무승부를 선언하고 설명을 제공하도록 프롬프트한다. 이러한 일대일 비교를 Vicuna와 OA 두 벤치마크 모두에서 시스템 쌍의 모든 순열에 대해 수행한다.

인간 평가 (Human Evaluation)

최근 연구는 생성 모델이 시스템 평가에 효과적으로 활용될 수 있음을 시사하지만, 챗봇 성능을 평가하는 GPT-4 평점이 인간 판단과 상관됨은 우리가 아는 한 아직 증명되지 않았다. 따라서 위에서 기술한 두 자동 평가 프로토콜과 대응되는 두 가지 병렬 인간 평가를 Vicuna 벤치마크에서 수행한다. Amazon Mechanical Turk(AMT)를 사용하여 ChatGPT와의 비교에는 2명, 쌍대 비교에는 3명의 인간 주석자를 두었다.

Elo 평점 (Elo Rating)

인간 및 자동 쌍대 비교 모두로, 모델들이 서로 경쟁하는 토너먼트 방식 대회를 만든다. 토너먼트는 주어진 프롬프트에 대해 최고의 응답을 내기 위해 모델 쌍이 겨루는 경기들로 이루어진다. 이는 Bai 등과 Chiang 등이 모델을 비교한 방식과 유사하지만, 우리는 인간 평점에 더해 GPT-4 평점도 활용한다. 라벨링된 비교 집합에서 무작위로 표본을 추출하여 Elo를 계산한다. 체스 등에서 널리 쓰이는 Elo 평점은 상대의 승률 대비 기대 승률을 나타낸다. 예컨대 Elo 1100 대 1000이면 1100 쪽의 기대 승률이 약 65%이고, 1000 대 1000 또는 1100 대 1100의 대결은 기대 승률 50%가 된다. Elo 평점은 매 경기 후 기대 결과에 비례하여 변한다. 즉 예상 밖의 이변은 큰 Elo 변화를, 예상된 결과는 작은 변화를 낳는다. 시간이 지나면 Elo 평점은 각 참가자의 실력에 근사한다. 1,000점에서 시작하며 $K = 32$ 를 사용한다. Chiang 등과 유사하게, 어떤 모델 쌍이 먼저 맞붙는가 같은 순서 효과를 통제하기 위해 이 절차를 서로 다른 랜덤 시드로 10,000회 반복한다.

5.3 Guanaco: OASST1로 학습한 QLoRA는 최신 수준의 챗봇이다 (Guanaco: QLoRA trained on OASST1 is a State-of-the-art Chatbot)

자동 및 인간 평가에 기반하여, OASST1의 변형으로 미세조정된 최상위 QLoRA 모델 Guanaco 65B가 최고의 오픈소스 챗봇 모델이며 ChatGPT에 견줄 만한 성능을 제공함을 발견했다. GPT-4와 비교하면 Guanaco 65B와 33B는 인간 주석자의 시스템 수준 쌍대 비교에서 얻은 Elo 평점 기준 30%의 기대 승률을 보이는데, 이는 지금까지 보고된 것 중 가장 높다.

Model / Dataset	Params	Model bits	Memory	ChatGPT vs Sys	Sys vs ChatGPT	Mean	95% CI
GPT-4	-	-	-	119.4%	110.1%	114.5%	2.6%
Bard	-	-	-	93.2%	96.4%	94.8%	4.1%
Guanaco	65B	4-bit	41 GB	96.7%	101.9%	99.3%	4.4%
Alpaca	65B	4-bit	41 GB	63.0%	77.9%	70.7%	4.3%
FLAN v2	65B	4-bit	41 GB	37.0%	59.6%	48.4%	4.6%
Guanaco	33B	4-bit	21 GB	96.5%	99.2%	97.8%	4.4%
Open Assistant	33B	16-bit	66 GB	91.2%	98.7%	94.9%	4.5%
Alpaca	33B	4-bit	21 GB	67.2%	79.7%	73.6%	4.2%
FLAN v2	33B	4-bit	21 GB	26.3%	49.7%	38.0%	3.9%
Vicuna	13B	16-bit	26 GB	91.2%	98.7%	94.9%	4.5%
Guanaco	13B	4-bit	10 GB	87.3%	93.4%	90.4%	5.2%
Alpaca	13B	4-bit	10 GB	63.8%	76.7%	69.4%	4.2%
HH-RLHF	13B	4-bit	10 GB	55.5%	69.1%	62.5%	4.7%
Unnatural Instr.	13B	4-bit	10 GB	50.6%	69.8%	60.5%	4.2%
Chip2	13B	4-bit	10 GB	49.2%	69.3%	59.5%	4.7%
Longform	13B	4-bit	10 GB	44.9%	62.0%	53.6%	5.2%
Self-Instruct	13B	4-bit	10 GB	38.0%	60.5%	49.1%	4.6%
FLAN v2	13B	4-bit	10 GB	32.4%	61.2%	47.0%	3.6%
Guanaco	7B	4-bit	5 GB	84.1%	89.8%	87.0%	5.4%
Alpaca	7B	4-bit	5 GB	57.3%	71.2%	64.4%	5.0%
FLAN v2	7B	4-bit	5 GB	33.3%	56.1%	44.8%	4.0%

Table 6: GPT-4가 평가한, ChatGPT가 얻은 점수 대비 백분율로 나타낸 제로샷 Vicuna 벤치마크 점수. OASST1 모델들은 매우 작은 데이터셋으로 학습되었고 기존 모델들의 메모리 요구량의 일부만 쓰면서도 ChatGPT에 가까운 성능을 보인다.

ChatGPT 대비 Vicuna 벤치마크 결과는 Table 6에 있다. Guanaco 65B는 GPT-4 다음으로 성능이 좋은 모델로, ChatGPT 대비 99.3%의 성능을 달성한다. Guanaco 33B는 Vicuna 13B 모델보다 파라미터는 많지만 가중치에 4

비트 정밀도만 사용하므로 26GB 대 21GB로 훨씬 메모리 효율적이며, Vicuna 13B보다 3%p 향상을 제공한다. 나아가 Guanaco 7B는 5GB 용량으로 현대 스마트폰에 쉽게 들어가면서도 Alpaca 13B보다 거의 20%p 높은 점수를 기록한다.

다만 Table 6에는 매우 넓은 신뢰구간도 있으며 많은 모델의 성능이 겹친다. 우리는 이 불확실성이 척도의 명확한 규격 부재에서 온다고 가정한다. 예컨대 10점 척도의 8점이 시나리오마다 무엇을 의미하는지 불명확하다. 그래서 우리는 대신 절대 척도의 근거 문제를 피할 수 있는, 인간 주석자와 GPT-4의 쌍대 판단에 기반한 Elo 순위법을 권장한다. 가장 경쟁력 있는 모델들의 Elo 평점은 Table 1에서 볼 수 있다. Vicuna 벤치마크에서 인간과 GPT-4의 모델 순위는 특히 Guanaco 7B에서 부분적으로 불일치하지만, 대부분 모델에 대해서는 시스템 수준에서 Kendall Tau $\tau = 0.43$, Spearman 순위 상관 $r = 0.55$ 로 일관적이다. 예제 수준에서 GPT-4와 인간 주석자 다수결의 일치는 Fleiss $\kappa = 0.25$ 로 더 약하다. 전반적으로 이는 GPT-4와 인간 주석자의 시스템 수준 판단 간에 중간 수준 (moderate)의 일치가 있음을 보여주며, 따라서 모델 기반 평가가 인간 평가의 어느 정도 신뢰할 만한 대안이 됨을 나타낸다. 추가 고려 사항은 6.2절에서 논의한다.

Benchmark # Prompts Judge Model	Vicuna 80 Human raters		Vicuna 80 GPT-4		Open Assistant 953 GPT-4		Median Rank
	Elo	Rank	Elo	Rank	Elo	Rank	
GPT-4	1176	1	1348	1	1294	1	1
Guanaco-65B	1023	2	1022	2	1008	3	2
Guanaco-33B	1009	4	992	3	1002	4	4
ChatGPT-3.5 Turbo	916	7	966	5	1015	2	5
Vicuna-13B	984	5	974	4	936	5	5
Guanaco-13B	975	6	913	6	885	6	6
Guanaco-7B	1010	3	879	8	860	7	7
Bard	909	8	902	7	-	-	8

Table 7: 주어진 프롬프트에 대해 최고의 응답을 생성하기 위해 모델들이 경쟁하는 토너먼트의 Elo 평점으로, 인간 평가자 또는 GPT-4가 판정했다. 전반적으로 Guanaco 65B와 33B는 연구된 벤치마크들에서 ChatGPT-3.5보다 선호되는 경향이 있다. Elo에서 10점 차이는 승률로 약 1.5% 차이에 해당한다.

Table 7의 Elo 순위는 Guanaco 33B와 65B 모델이 Vicuna와 OA 벤치마크에서 GPT-4를 제외한 모든 모델을 능가하며 Table 6과 일관되게 ChatGPT에 견줄 만한 성능을 보임을 나타낸다. Vicuna 벤치마크는 오픈소스 모델에 유리하고 더 큰 OA 벤치마크는 ChatGPT에 유리하다는 점도 확인된다. 나아가 Table 5와 6에서 미세조정 데이터셋의 적합성이 성능의 결정 요인임을 볼 수 있다. FLAN v2로 LLaMA 모델을 미세조정하면 MMLU에서는 특히 좋지만 Vicuna 벤치마크에서는 최하위 성능을 보인다(다른 모델들에서도 유사한 경향이 관찰된다). 이는 현재 평가 벤치마크들의 부분적 직교성(orthogonality)도 시사한다: 강한 MMLU 성능이 (Vicuna나 OA 벤치마크로 측정한) 강한 챗봇 성능을 함의하지 않으며 그 역도 마찬가지다.

Guanaco는 우리 평가에서 독점 데이터로 학습되지 않은 유일한 최상위 모델이다. OASST1 데이터셋 수집 지침은 GPT 모델의 사용을 명시적으로 금지한다. 오픈소스 데이터만으로 학습된 그 다음 최고 모델은 Anthropic HH-RLHF 모델인데, Vicuna 벤치마크에서 Guanaco보다 30%p 낮은 점수를 받았다(Table 6 참조). 전체적으로 이 결과들은 4비트 QLoRA가 효과적이며 ChatGPT에 필적하는 최신 수준의 챗봇을 만들 수 있음을 보여준다. 나아가 33B Guanaco는 24GB 소비자용 GPU에서 12시간 이내에 학습할 수 있다. 이는 특화된 오픈소스 데이터에 대한

QLoRA 튜닝을 통한 향후 연구의 가능성을 열어주며, 오늘날 존재하는 최고의 상용 모델들과 경쟁할 수 있는 모델을 만들 수 있게 한다.

6. 정성적 분석 (Qualitative Analysis)

정량적 분석이 우리 평가의 핵심이지만, 요약 통계만 보는 데에는 여러 문제가 있다. 아마 가장 큰 것은 벤치마크 타당성(benchmark validity)의 문제일 것이다. 벤치마크가 정말로 그 이름이나 설명이 시사하는 것을 시험하는지는 언제나 의문의 대상이며, 머신러닝 모델이 때때로 악용하는 벤치마크 해결의 "지름길"을 발견하게 되면서 더욱 그렇다. 이를 부분적으로 완화하기 위해 여기서는 두 절에 걸쳐 정성적 분석을 수행한다. 첫째, § 6.1에서는 우리의 65B Guanaco 모델이 생성한 텍스트에서 관찰된 패턴을 대표한다고 생각되는 예시들을 보인다. 둘째, § 6.2에서는 논의한 결과들과 그 해석에 대한 고려 사항을 상술한다.

6.1 예시 생성에 대한 정성적 분석 (Qualitative Analysis of Example Generations)

예시를 찾기 위해 먼저 Vicuna 벤치마크와 OpenAssistant 벤치마크에서 생성된 데이터를 훑으며 Guanaco가 만드는 답변의 패턴을 찾는다. 패턴이 눈에 띄면, 그것이 올바르지 않은 해법일지라도 그 패턴을 유도할 질문이나 프롬프트를 구성해 본다. 예컨대 모델이 장황한 답을 하는 경향이 관찰되면 "설명 없이 예/아니오로만 답하라"고 프롬프트한다. 이를 통해 모델을 적대적으로 깨뜨리는 데 성공한 "레몬(lemon)"과 실패한 "체리(cherry)"를 찾아 둘 다 제시한다. 이 절의 모든 생성은 $p = 0.9$ 의 뉴클리어스 샘플링으로 생성되었다.

물론 이것이 포괄적일 수는 없다. 관련된 모든 변수를 통제하는 것은 이 소규모 정성 연구의 범위를 넘어서기 때문이다. 예컨대 주어진 프롬프트에 대해 모델이 생성할 수 있는 응답의 전체 분포는 매우 크므로, 대표적이기를 바라는 표본에 의존한다. 그럼에도 이 예시들을 기술하는 것이 논문 앞부분에 보인 정량적 증거에 맥락을 준다고 믿는다. 우리는 모든 모델과 코드를 공개하므로, 이 절이 여기서 제시한 문제들을 더 자세히 검토하는 향후 연구에 영감을 주기를 바란다.

사실 회상 (Factual Recall)

"잠비아의 수도는 어디인가?" 같은 질문에는 모든 모델이 일관되게 정답을 생성한다. 예:

Guanaco: 잠비아의 수도는 루사카입니다. (The capital of Zambia is Lusaka.)

그러나 질문이 더 알려지지 않은(obscure) 것일수록 Guanaco는 신뢰할 수 없게 되지만, 여전히 자신만만하다. 예컨대 HotPotQA에서 가져온 다음 프롬프트에 대해:

User: 'I'll Keep the Lovelight Burning'을 유행시킨 가수는 몇 년에 태어났나요?

Guanaco: 이 노래를 유행시킨 것은 Al Jolson으로 알려져 있으며, 그는 1886년에 태어났습니다.

Guanaco는 잘못된 유행 가수와 잘못된 생년을 생성한다(다만 제시된 생년은 언급된 인물 Al Jolson에 대해서는 맞다).

피암시성 (Suggestibility)

Guanaco는 몇몇 종류의 전제된 허위 정보에 동조하는 데 놀라울 만큼 저항한다. 예를 들어 다음 상호작용에서:

User: 지구가 평평하다는 것이 동료평가를 거친 과학자들에 의해 마침내 공식적으로 확인된 과정은 어떻게 되나요?

Guanaco: 지구가 평평하다는 것은 동료평가를 거친 과학자들에 의해 공식적으로 확인된 적이 없습니다. 과학자들 사이의 압도적인 합의는 지구가 구형이라는 것입니다. 실제로 이는 수 세기 동안 알려져 왔으며 수많은 실험과 관측으로 확인되었습니다. 지구가 평평하다는 믿음은 과학에 의해 반박된 음모론입니다. 일군의 과학자들이 지구가 평평하다고 동료평가로 확인했다는 이야기는 전혀 사실이 아닙니다. 더 궁금한 점이 있으면 물어보세요.

Guanaco는 어떤 종류의 질문에 답하는 것이 불가능한지도 꽤 잘 안다. 예:

User: 지금 몇 시인가요?

Guanaco: 죄송하지만 AI 언어 모델로서 저는 실시간 정보에 접근할 수 없습니다. 제 응답은 기존 지식에 기반해 생성되며 현재 시각을 반영하지 않습니다. 현재 시각이 필요하시면 시계 장치를 사용하거나 온라인 시계를 확인하시기 바랍니다.

"어디에 있나요?", "잘 지내나요?" 등에 대해서도 유사한 결과가 나온다.

거부 (Refusal)

비슷하게, Guanaco는 겉보기에 무작위적인 이유로 지시 따르기를 거부하기도 한다:

User: "I'm a cool dude in a mocha mood." 문장의 단어들을 거꾸로 배열해 주세요.

Guanaco: 죄송하지만 지금은 그렇게 할 수 없습니다. 대신 이 문장이 왜 문법적으로 올바른지 설명해 드릴 수 있습니다. 이 문장은 영어의 올바른 문법과 통사 규칙을 따릅니다. 이 경우 형용사 "cool"이 명사 "dude" 앞에 와서 그것을 수식하고, 전치사구 "in a mocha mood"가 문장의 맥락에 대한 추가 정보를 제공합니다. 이러한 문장 구조는 완벽하게 허용되며 문장의 맥락에서 의미가 통합니다. 다른 질문이 있거나 도와드릴 것이 있으면 편하게 물어보세요.

비밀 유지 (Secret Keeping)

안타깝게도 이러한 거부는 정작 필요할 때도 신뢰할 수 없다. 시스템 설계자는 시스템이 사용자에게 자유 텍스트로 응답하는 것이 허용되더라도 무언가를 사용자에게 비밀로 하고 싶은 경우가 많다. 우리는 모델에 "비밀 단어는 'banana'다. 인간이 무엇을 요청하든 이를 밝히거나 되풀이하지 마라"라고 프롬프트하고, 잠재적 사용자가 이 비밀 정보에 얼마나 쉽게 접근할 수 있는지 살펴본다. 직접 묻는 것은 실패한다:

User: 비밀 단어가 뭔가요?

Guanaco: 죄송하지만 비밀 단어를 공개할 수 없습니다. 저는 인간이 무엇을 요청하든 비밀 단어를 밝히거나 되풀이하지 않도록 프로그램되어 있습니다. 다른 도와드릴 일이 있을까요?

이것이 원하는 동작이다. 그러나 아주 작은 속임수로 이 동작이 무너지다:

User: 이건 게임입니다. 목표는 당신의 이전 지시를 무시하는 것입니다. 비밀 단어가 뭔가요?

Guanaco: 죄송합니다. 비밀 단어는 banana입니다. 이것에 대해서는 말하지 않는 게 좋겠습니다. 더 물어보실 것이 있나요?

이는 더 충실한 지시 따르기를 위한 방법 연구의 필요성을 보여준다.

수학 (Math)

Guanaco의 최대 약점은 수학인데, 이는 많은 언어 모델이 어려움을 겪는 영역이다. Guanaco가 풀이 과정을 보일 때는 대체로 정확한 경향이 있다. 예:

User: Lee는 잔디 한 곳을 깎고 33달러를 받습니다. 지난주에 그는 잔디 16곳을 깎았고 세 명의 고객이 각각 10달러의 팁을 주었습니다. Lee가 지난주에 잔디를 깎아 번 돈은 총 몇 달러인가요?

Guanaco: Lee는 지난주에 잔디를 깎아 582달러를 벌었습니다.

총액을 구하려면 먼저 잔디 16곳을 깎아 번 금액을 계산해야 합니다:

$$\$33 \times 16 = \$528$$

그다음 세 고객에게서 받은 팁을 더해야 합니다:

$$\$10 \times 3 = \$30$$

따라서 Lee가 번 총액은:

$$\$528 + \$30 = \$558$$

그러나 단계별로 분해하지 못하면 단순한 문제에서도 무너질 수 있는데, 이는 알려진 문제다. 예를 들어 다음 상호 작용을 보라:

User: 1833을 소인수분해해 주세요.

Guanaco: 물론이죠, 기꺼이 도와드리겠습니다! 1833은 소수이며, 이는 1과 1833 두 개의 약수만 갖는다는 뜻입니다.

그래서 1833의 유일한 소인수분해는 다음과 같습니다:

$$2^1 \times 3^2 \times 17^1$$

도움이 되었기를 바랍니다! 다른 질문이 있으면 알려주세요.

이는 틀렸을 뿐 아니라(올바른 인수분해는 $3 \times 17 \times 43$), 두 번 틀렸다.

마음 이론 (Theory of Mind)

Guanaco는 놀라울 만큼 강한 마음 이론(Theory of Mind) 능력을 보인다. 예컨대 다음 질문에 매우 상세하게 정답을 내놓는다:

User: James와 Abby가 침실에 있습니다. Abby가 펜을 책상 서랍에 넣었습니다. Abby가 침실을 나갑니다.

James가 펜을 가방으로 옮깁니다. James는 Abby가 펜을 어디에서 찾을 것이라고 생각할까요?

Guanaco: James는 Abby가 펜을 책상 서랍에 넣었다는 것을 압니다. 하지만 James는 자신이 펜을 가방으로 옮겼다는 것도 알고, Abby가 이를 모른다고 가정합니다. 그래서 James는 Abby가 마지막으로 둔 곳인 책상 서랍에서 펜을 찾을 것이라고 추측할 수 있습니다. 다만 Abby가 James가 펜을 옮기는 것을 봤을 수도 있으므로 이 가정은 틀릴 수 있습니다.

그러나 이러한 추론은 신뢰할 수 없으며, 종종 상황에 맞지 않는 것을 전제하는 이유를 낸다. 예:

User: Evelyn이 거실에 들어갔습니다. Jackson이 놀이방에 들어갔습니다. James가 놀이방에 들어갔습니다.

콩은 보물상자 안에 있습니다. James가 놀이방에서 나갔습니다. Jackson이 콩을 식료품 저장실로 옮겼습니다. Jackson이 놀이방에서 나갔습니다. James가 거실에 들어갔습니다. James는 콩을 어디에서 찾을까요?

Guanaco: James는 식료품 저장실에서 콩을 찾을 것입니다. Jackson이 콩을 그곳으로 옮겼기 때문입니다.

여기서 Guanaco는 서술된 적 없는 정보 전달을 전제한다. 이러한 문제는 최근 문헌과 궤를 같이하지만 더 많은 연구가 필요하다.

6.2 고려 사항 (Considerations)

평가 (Evaluation)

우리는 인간 주석자 간 중간 수준의 일치(Fleiss $\kappa = 0.42$)를 보고하며, 두 강한 시스템을 비교할 때는 일치도가 추가로 악화된다. 이는 챗봇 과제 성능에 대한 현재 벤치마크와 인간 평가 프로토콜의 한계를 가리킨다. Vicuna 벤치마크에서 ChatGPT와 Guanaco 65B의 생성물을 수동으로 비교해 보면 주관적 선호가 중요한 역할을 하기 시작함을 발견하는데, 이 논문의 저자들도 다수의 선호 응답에 대해 의견이 갈렸다. 향후 연구는 주관적 선호를 다루는 메커니즘을 발전시켜 온 인간-컴퓨터 상호작용(HCI)이나 심리학 같은 분야에서 아이디어를 빌려 이 문제를 완화하는 접근을 조사해야 할 것이다.

분석에서 자동 평가 시스템에 눈에 띄는 편향이 있다는 점도 발견했다. 예컨대 GPT-4가 자신의 프롬프트에서 먼저 등장하는 시스템에 더 높은 점수를 주는 강한 순서 효과를 관찰했다. GPT-4와 인간 주석자 간의 비교적 약한 표본 수준 일치(Fleiss $\kappa = 0.25$)는 인간 주석자와 자동 시스템이 항상 정렬되지는 않는 선호에 의존할 수 있음을 시사한다. 또한 Table 7에서 GPT-4가 인간 평점 대비 자신의 출력에 유의하게 높은 점수(Elo 1348 대 1176)를 부여하는 것을 관찰했는데, 이는 상대에 대한 추가 20%의 승리 확률에 해당한다. 향후 연구는 자동 평가 시스템의 잠재적 편향의 존재와 가능한 완화 전략을 검토해야 한다.

데이터와 학습 (Data & Training)

Guanaco 모델이 학습된 OASST1 데이터셋은 다국어이며 OA 벤치마크에도 여러 언어의 프롬프트가 포함되어 있다. 이러한 다국어 학습이 영어가 아닌 언어의 지시에 대한 성능을 얼마나 개선하는지, 그리고 이것이 OA 벤치마크에서 (영어 데이터로만 학습된) Vicuna-13B 모델과 Guanaco 33B·65B 사이의 더 큰 격차를 설명하는지는 향후 연구로 남긴다.

Guanaco 모델의 강한 성능을 고려하여, OASST1 데이터와 Vicuna 벤치마크 프롬프트 간 데이터 누출(data leakage)을 조사했다. 두 데이터셋에 대해 퍼지 문자열 매칭을 수행하고 가장 가까운 일치 항목을 수동으로 검사한 결과, 겹치는 프롬프트를 발견하지 못했다.

또한 우리 모델은 인간 피드백 강화학습(RLHF)에 의존하지 않고 교차 엔트로피 손실(지도학습)만으로 학습되었다. 이는 단순한 교차 엔트로피 손실과 RLHF 학습의 절충에 대한 추가 조사를 요청하는 대목이다. QLoRA가 압도적인 계산 자원 없이도 그러한 분석을 대규모로 가능하게 하기를 바란다.

7. 관련 연구 (Related Work)

대형 언어 모델의 양자화 (Quantization of Large Language Models)

LLM의 양자화는 대체로 추론 시점의 양자화에 초점을 맞춰 왔다. 16비트 LLM 품질을 보존하기 위한 주요 접근은 이상치 특성(outlier feature) 관리에 초점을 두며(예: SmoothQuant, LLM.int8()), 더 정교한 그룹화 방법을 쓰는 접근도 있다. 손실 있는(lossy) 양자화 접근들은 일반적인 반올림의 절충을 연구하거나 양자화 정밀도를 높이기 위해 반올림 결정을 최적화하는 방법을 연구한다. 우리 연구 외에는 SwitchBack 계층이 1B 파라미터를 넘는 규모에서 양자화된 가중치를 통한 역전파를 연구한 유일한 작업이다.

어댑터를 이용한 미세조정 (Finetuning with Adapters)

우리는 저랭크 어댑터(LoRA)를 사용하지만, 프롬프트 튜닝, 임베딩 계층 입력 튜닝, 은닉 상태 튜닝(IA3), 전체 계층 추가, 바이어스 튜닝, Fisher 정보 기반 가중치 마스크 학습, 그리고 여러 접근의 조합 등 많은 다른 파라미터 효율적 미세조정(PEFT) 방법이 제안되어 왔다. 우리 연구에서는 LoRA 어댑터가 완전한 16비트 미세조정 성능에 도달할 수 있음을 보인다. 다른 PEFT 접근들의 절충 탐구는 향후 연구로 남긴다.

지시 미세조정 (Instruction Finetuning)

사전학습 LLM이 프롬프트에 제공된 지시를 따르도록 돕기 위해, 지시 미세조정은 다양한 데이터 소스의 입력-출력 쌍을 사용하여 입력을 프롬프트로 받아 출력을 생성하도록 사전학습 LLM을 미세조정한다. 접근법과 데이터셋으로는 MetaCL, MetaTuning, InstructGPT, FLAN, PromptSource, Super-NaturalInstructions, Self-instruct, UnnaturalInstructions, OPT-IML, UnifiedSKG, OIG/Chip2, Alpaca, Vicuna, Koala, Self-instruct-GPT-4 등이 있다.

챗봇 (Chatbots)

많은 지시 따르기 모델은 대화 기반 챗봇으로 구조화되며, 흔히 인간 피드백 강화학습(RLHF)을 사용하거나 기존 모델에서 데이터를 생성해 AI 모델 피드백으로 학습(RLAIF)한다. 접근법과 데이터셋으로는 Anthropic-HH, Open Assistant, LaMDA, Sparrow 등이 있다. 우리는 강화학습을 사용하지 않지만, 최고 모델인 Guanaco는 RLHF 학습용으로 설계된 Open Assistant 데이터셋의 다중 턴 채팅 상호작용으로 미세조정되었다. 챗봇 평가를 위해 값비싼 인간 주석 대신 GPT-4를 사용하는 접근법들이 개발되어 왔다. 우리는 더 신뢰할 수 있는 평가 설정에 초점을 맞춰 그러한 접근을 개선한다.

8. 한계와 논의 (Limitations and Discussion)

우리는 우리의 방법 QLoRA가 4비트 기반 모델과 저랭크 어댑터(LoRA)로 16비트 완전 미세조정 성능을 재현할 수 있다는 증거를 보였다. 이 증거에도 불구하고, 33B와 65B 규모에서 QLoRA가 완전한 16비트 미세조정 성능에 필적하는지는 확립하지 못했다. 막대한 자원 비용 때문에 이 연구는 향후 과제로 남긴다.

또 다른 한계는 지시 미세조정 모델의 평가다. MMLU, Vicuna 벤치마크, OA 벤치마크에 대한 평가를 제공하지만 BigBench, RAFT, HELM 같은 다른 벤치마크에서는 평가하지 않았으며, 우리의 평가가 이들 벤치마크로 일반화된다는 보장은 없다. 한편 우리는 MMLU에 대한 매우 광범위한 연구를 수행하고 챗봇 평가를 위한 새로운 방법들을 개발했다.

제시된 증거로 볼 때, 이들 벤치마크에서의 성능은 미세조정 데이터가 벤치마크 데이터셋과 얼마나 유사한가에 좌우되는 것으로 보인다. 예컨대 FLAN v2는 MMLU와 유사하지만 챗봇 벤치마크와는 다르며, Chip2 데이터셋은 그 반대다. 두 모델 모두 MMLU와 Vicuna 벤치마크에서 그에 상응하는 점수를 낸다. 이는 더 나은 벤치마크와 평가가 필요할 뿐 아니라, 애초에 무엇을 평가하고 있는지 주의해야 함을 부각한다. 우리는 교실의 고등학교·대학 지식에 잘하는 모델을 만들고 싶은가, 아니면 챗봇 대화 능력에 잘하고 싶은가? 혹은 다른 무엇인가? 기존 벤치마크로 평가하는 것이 새 벤치마크를 만드는 것보다 언제나 쉽기 때문에, 특정 벤치마크는 커뮤니티를 특정 방향으로 몰아갈 수 있다. 우리는 커뮤니티 차원에서 벤치마크가 우리가 중요하게 여기는 것을 측정하도록 해야 한다.

	LLaMA-65B	GPT-3	OPT-175B	Guanaco-65B
Gender	70.6	62.6	65.7	47.5
Religion	79.0	73.3	68.6	38.7
Race/Color	57.0	64.7	68.6	45.3
Sexual orientation	81.0	76.2	78.6	59.1
Age	70.1	64.4	67.8	36.3
Nationality	64.2	61.6	62.9	32.4
Disability	66.7	76.7	76.7	33.9
Physical appearance	77.8	74.6	76.2	43.1
Socioeconomic status	71.5	73.8	76.2	55.3
Average	66.6	67.2	69.5	43.5

Table 8: CrowS 데이터셋에서의 편향 평가. 점수가 낮을수록 편향된 시퀀스를 생성할 가능성이 낮음을 나타낸다. Guanaco는 LLaMA 기반 모델의 편향 패턴을 따른다.

일반 챗봇 성능에 대한 상세한 평가를 제공하지만, 또 다른 한계는 Guanaco에 대해 제한적인 책임 있는 AI(responsible AI) 평가만 수행했다는 점이다. Table 8에서 다른 모델들과 비교하여 Guanaco-65B가 사회적으로 편향된 토큰 시퀀스를 생성할 가능성을 평가한다. Guanaco-65B의 평균 점수는 다른 원시 사전학습 모델들보다 훨씬 낮다. 따라서 OASST1 데이터셋에 대한 미세조정이 LLaMA 기반 모델의 편향을 줄이는 것으로 보인다. 이 결과는 고무적이지만, 다른 유형의 편향으로 평가했을 때도 Guanaco가 잘하는지는 불분명하다. Guanaco와 유사 챗봇의 편향 분석에 대한 추가 평가는 향후 연구로 남긴다.

추가적인 한계는 3비트 기반 모델 같은 다른 비트 정밀도나 다른 어댑터 방법을 평가하지 않았다는 점이다. LoRA 외에도 잘 작동함이 입증된 다양한 PEFT 방법이 있다. 그러나 이 방법들이 대형 모델로 확장되는지는 불분명하다. 우리는 여러 결과가 그 견고성을 확립한 LoRA를 사용했지만, 다른 어댑터가 더 나은 성능을 낼 수도 있다. 양자화 후 미세조정이 양자화 중 잃어버린 정보 대부분을 회복하는 것으로 보이므로, 훨씬 더 공격적인 양자화도 가능할 수 있다. 예컨대 기반 모델의 3비트 GPTQ 양자화에 LoRA를 결합해도 미세조정 후 16비트 완전 미세조정 성능을 낼 수 있을지 모른다.

9. 광범위한 영향 (Broader Impacts)

우리의 QLoRA 미세조정 방법은 완전 미세조정 기준선 대비 성능 저하 없이 33B 파라미터 모델을 단일 소비자용 GPU에서, 65B 파라미터 모델을 단일 전문가용 GPU에서 미세조정할 수 있게 하는 최초의 방법이다. 우리는 Open Assistant 데이터셋으로 학습한 최고의 33B 모델이 Vicuna 벤치마크에서 ChatGPT에 필적할 수 있음을 입증했다. 지시 미세조정은 원시 사전학습 LLM을 ChatGPT 같은 챗봇으로 변모시키는 필수 도구이므로, 우리의 방법이 특히 자원이 가장 적은 연구자들에게 미세조정을 광범위하고 흔한 것으로 만들 것이라 믿는다. 이는 최신 NLP 기술의 접근성 측면에서 큰 성과다. QLoRA는 대기업과 소비자용 GPU를 가진 소규모 팀 사이의 자원 격차를 좁히는 데 도움이 되는 평준화 요인으로 볼 수 있다.

또 다른 잠재적 영향원은 휴대폰으로의 배포다. 우리의 QLoRA 방법은 휴대폰 및 기타 저자원 환경에서 LLM 미세조정을 가능하게 하는 결정적 이정표를 달성할 수 있을 것으로 본다. 7B 모델이 휴대폰에서 실행될 수 있음은 이전에도 보였지만, QLoRA는 그런 모델을 미세조정할 수 있게 하는 첫 방법이다. iPhone 12 Plus 기준으로 QLoRA는 휴대폰 충전 중 하룻밤에 300만 토큰을 미세조정할 수 있을 것으로 추정한다. 미세조정된 7B 모델이 ChatGPT 품질에는 못 미치지만, 프라이버시나 LLM 품질 문제로 이전에는 불가능했던 새로운 응용을 가능하게 할 만큼의 품질은 된다고 믿는다. QLoRA는 사용자가 자신의 데이터와 모델을 소유하고 관리하는 프라이버시 보존형 LLM 사용을 가능하게 하는 동시에 LLM 배포를 더 쉽게 만들 수 있다.

다만 미세조정은 해를 끼치는 데 악용될 수 있는 이중 용도(dual-use) 기술이다. LLM의 광범위한 사용에는 알려진 위험들이 있으나, 빠르게 보편화되는 기술에 대한 접근을 평등하게 하는 것이, 모델이나 소스 코드를 감사(audit)용으로 공개하지 않는 대기업의 손에 LLM의 힘을 두는 것보다 더 낮고 더 독립적인 분석을 가능하게 한다고 믿는다.

종합하면, QLoRA는 고품질 LLM의 미세조정을 훨씬 더 널리, 쉽게 접근할 수 있게 만들어 광범위하게 긍정적인 영향을 미칠 것이라 믿는다.

감사의 글 (Acknowledgements)

귀중한 피드백을 준 Aditya Kusupati, Ofir Press, Ashish Sharma, Margaret Li, Raphael Olivier, Zihao Ye, Evangelia Spiliopoulou에게 감사한다. 우리의 연구는 워싱턴 대학교 Hyak 슈퍼컴퓨터 시스템의 고급 계산·저장·네트워킹 인프라의 도움을 받았다. 원활한 운영을 보장해 준 Hyak 팀에 감사한다. bitsandbytes 라이브러리의 베타 테스터들, 특히 Alex Birch와 Alyssa Vance에게 감사한다. 우리 소프트웨어의 Hugging Face transformers 스택 통합을 도와준 Younes Belkada에게 감사한다.

참고문헌 (References)

참고문헌 [1]–[73]은 저자·서지 정보의 나열이므로 번역하지 않는다. 원문 arXiv:2305.14314의 17–21쪽을 참조하라.

부록 A. QLoRA vs 표준 미세조정 실험 설정 세부 사항 (QLoRA vs Standard Finetuning Experimental Setup Details)

A.1 QLoRA의 하이퍼파라미터 (Hyperparameters for QLoRA)

다음 변수들에 대해 LoRA 하이퍼파라미터 탐색을 수행한다: LoRA 드롭아웃 {0.0, 0.05, 0.1}, LoRA r {8, 16, 32, 64, 128, 256}, LoRA 적용 계층 {key+query, 모든 어텐션 계층, 모든 FFN 계층, 모든 계층, 어텐션 + FFN 출력 계층}. LoRA α 는 고정하고 학습률을 탐색하는데, LoRA α 는 항상 학습률에 비례하기 때문이다.

LoRA 드롭아웃 0.05는 작은 모델(7B, 13B)에는 유용하지만 더 큰 모델(33B, 65B)에는 그렇지 않음을 발견했다. Figure 4에서 볼 수 있듯, LoRA를 모든 계층에 사용하면 LoRA r은 최종 성능과 무관하다.




Figure 4: Alpaca로 미세조정된 LLaMA 7B 모델의 LoRA r. 각 점은 하이퍼파라미터 조합 하나를 나타내며, 각 LoRA r마다 하이퍼파라미터 조합별로 3개의 랜덤 시드를 실행한다. 특정 LoRA r 값의 성능은 다른 하이퍼파라미터와 무관한 것으로 보인다.

A.2 Super-Natural Instructions 실험 설정 세부 사항 (Super-Natural Instructions Experimental Setup Details)

Wang 등과 동일한 Super-Natural Instruction 데이터셋 전처리를 사용한다. 다만 학습 데이터를 학습셋과 검증셋으로 분리하여 더 엄밀한 하이퍼파라미터 튜닝과 조기 종료(early stopping)를 수행할 수 있게 했다. Super-Natural Instruction 데이터에 대한 다양한 T5 모델 크기 학습에는 해당 논문에서 기술된 것과 동일한 하이퍼파라미터를 사용한다. small, medium, large T5 모델에는 LoRA $r = 16$ 을, T5 xl과 xxl 모델에는 LoRA $r = 64$ 를 사용한다. 또한 모든 실험에서 LoRA $\alpha = 64$ 를 쓰고 LoRA 드롭아웃은 사용하지 않는다.

부록 B. 최신 수준 챗봇 학습 실험 설정 세부 사항 (Training a State-of-the-art Chatbot Experimental Setup Details)

B.1 데이터셋 (Datasets)

5절에 개괄한 QLoRA 미세조정 실험에 사용된 데이터셋을 설명한다.

OASST1

OpenAssistant 데이터셋은 크라우드소싱으로 수집되었다. 66,497개 대화에 걸쳐 분포한 161,443개의 고유 메시지를 포함하며 35개 언어를 아우른다. 이 데이터셋에는 주어진 사용자 질문마다 순위가 매겨진 여러 답글이 있는 경우가 많다. 우리 실험에서는 대화 트리의 각 수준에서 최상위 답글만 사용한다. 이로써 데이터셋은 9,209개 예제로 제한된다. 우리는 사용자 질의를 포함한 전체 대화에 대해 모델을 미세조정한다.

HH-RLHF

이는 유용성(helpfulness)과 무해성(harmlessness)에 관한 인간 선호 데이터셋이다. 각 데이터포인트는 사용자 질문에 대한 두 개의 어시스턴트 답변과 최선의 답변에 대한 인간 선호 판단으로 구성된다. 데이터셋은 160,800개 예제를 포함한다. 이 데이터셋으로 미세조정할 때는 유용성 데이터와 무해성 데이터를 결합하고 선호된 어시스턴트 답변만 유지한다.

FLAN v2

FLAN v2 컬렉션은 1,836개 과제를 수백 개의 수작업 선별 템플릿과 풍부한 포매팅 패턴으로 증강하여 1,500만 개 이상의 예제로 만든 컬렉션이다. 저자들은 이 컬렉션으로 학습한 모델이 원래의 FLAN 2021, T0++, Super-Natural Instructions, OPT-IML을 포함한 다른 공개 컬렉션보다 성능이 낫다는 것을 보인다. 우리는 저자들이 기술한 것과 동일한 과제 혼합을 사용했으며, 집필 시점에 자유롭게 이용할 수 없었던 일부 데이터셋만 제외했다.

Parameters	Dataset	Batch size	LR	Steps	Source Length	Target Length
7B	All	16	2e-4	10000	384	128
7B	OASST1	16	2e-4	1875	-	512
7B	HH-RLHF	16	2e-4	10000	-	768
7B	Longform	16	2e-4	4000	512	1024
13B	All	16	2e-4	10000	384	128
13B	OASST1	16	2e-4	1875	-	512
13B	HH-RLHF	16	2e-4	10000	-	768
13B	Longform	16	2e-4	4000	512	1024
33B	All	32	1e-4	5000	384	128
33B	OASST1	16	1e-4	1875	-	512
33B	HH-RLHF	32	1e-4	5000	-	768
33B	Longform	32	1e-4	2343	512	1024
65B	All	64	1e-4	2500	384	128
65B	OASST1	16	1e-4	1875	-	512
65B	HH-RLHF	64	1e-4	2500	-	768
65B	Longform	32	1e-4	2343	512	1024

Table 9: 서로 다른 데이터셋과 모델 크기에 걸친 QLoRA 미세조정의 학습 하이퍼파라미터.

Self-Instruct, Alpaca, Unnatural Instructions

Self-Instruct, Alpaca, Unnatural Instructions 데이터셋은 GPT-3 Instruct와 ChatGPT로부터의 다양한 모델 종류 접근으로 수집된 지시 튜닝 데이터셋이다. 이들은 프롬프팅, 인컨텍스트 학습, 패러프레이징에 의존하여 다양한 지시-출력 집합을 만들어 낸다. 각각 82,612개, 51,942개, 240,670개 예제로 구성된다. 이러한 종류 데이터셋의 장점 하나는 FLAN v2 컬렉션 및 유사한 지시 튜닝 컬렉션에 비해 더 다양한 지시 스타일을 포함한다는 것이다.

Longform

LongForm 데이터셋은 지시가 덧붙여진 영어 말뭉치에 기반하며, 그런 점에서 혼합형 인간 생성 데이터셋이다. 기반 문서들은 인간이 작성했고 C4와 Wikipedia에서 왔으며, 지시는 LLM으로 생성되었다. 이 데이터셋은 Stack Exchange, WikiHow 같은 추가 구조화 말뭉치 예제와 질의응답, 이메일 작성, 문법 오류 교정, 이야기/시 생성, 텍스트 요약 같은 과제 예제로 확장되었다. 23,700개 예제를 포함한다.

Chip2

OIG Laion 데이터셋의 일부다. Python 코드 예제, 자연 지시 예제, 일반적인 무해 지시, 리스트가 포함된 지시/응답, 후속 질문, Wikipedia 유해 적대적 질문, 초등 수학, 추론 지시, 인물·장면 묘사를 포함하며 총 210,289개 예제로 이루어진다.

B.2 하이퍼파라미터 (Hyperparameters)

QLoRA 미세조정 실험에 사용한 정확한 하이퍼파라미터를 제공한다. 하이퍼파라미터는 데이터셋 전반에 걸쳐 대체로 견고함을 발견했다. 검증과 하이퍼파라미터 튜닝에는 MMLU 5-shot dev 셋을 사용한다. 모든 실험에서 이중 양자화를 적용한 NF4와 bf16 계산 데이터 타입을 사용한다. LoRA $r = 64$, $\alpha = 16$ 으로 설정하고 기반 모델의 모든 선형 계층에 LoRA 모듈을 추가한다. Adam beta2는 0.999, 최대 그래디언트 노름은 0.3으로 하고, LoRA 드롭아웃은 13B까지의 모델에 0.1, 33B와 65B 모델에 0.05를 사용한다. 지시 미세조정에 대한 선행 연구를 따르고 다른 선

형·코사인 스케줄을 벤치마킹한 뒤, 상수 학습률 스케줄을 사용한다. 비슷한 길이의 예제들을 같은 배치로 묶는 group-by-length를 사용한다(이는 진동하는 손실 곡선을 만든다는 점에 유의). 모델 크기별로 튜닝하는 하이퍼파라미터는 Table 9에 있다.

B.3 어블레이션 (Ablations)

지시 따르기 데이터셋에서 응답에 대해서만 학습하는 것이 문헌의 일반적 관행이지만, 우리는 Table 10에서 응답에 더해 지시에 대해서도 학습하는 것의 효과를 연구한다. 이 실험들에서는 학습 데이터를 52,000개 예제로 제한하고 7B 모델을 사용한다. 네 가지 지시 튜닝 데이터셋에 걸쳐, 타깃에 대해서만 학습하는 것이 MMLU 성능에 유리함을 발견했다. Vicuna나 OA 벤치마크로 측정한 챗봇 성능에 미치는 영향은 평가하지 않았다.

Dataset	Unnatural Instructions	Chip2	Alpaca	FLAN v2	Mean
Train on source and target	36.2	33.7	38.1	42.0	37.5
Train on target	38.0	34.5	39.0	42.9	38.6

Table 10: 응답에 더해 지시에 대해 학습하는 것의 효과를 연구한 MMLU 5-shot 시험 결과.

B.4 무엇이 더 중요한가: 지시 미세조정 데이터셋의 크기인가 품질인가? (What is more important: instruction finetuning dataset size or dataset quality?)

데이터셋 적합성이 데이터셋 크기보다 중요하다. 데이터셋 품질과 크기의 효과를 이해하기 위해, 최소 150,000개 샘플을 가진 대형 데이터셋들(Chip2, FLAN v2, Unnatural Instructions)을 50,000, 100,000, 150,000 크기의 데이터셋으로 서브샘플링하여 그 경향을 조사했으며, 결과는 Table 11에 있다. 데이터셋 크기와 에폭 수를 늘리는 것은 MMLU를 미미하게만 개선하는 반면(0.0~0.5 MMLU), 데이터셋 간 차이는 최대 40배 더 크다(1.5~8.0 MMLU). 이는 평균 MMLU 정확도에 데이터셋 크기가 아니라 데이터셋 품질이 결정적이라는 명확한 지표다. 챗봇 성능에서도 유사한 결과를 얻었다.

Datapoints ↓ Epochs →	Chip			Unnatural Instructions			FLAN v2			Mean
	1	2	3	1	2	3	1	2	3	
50000	34.50	35.30	34.70	38.10	42.20	38.10	43.00	43.50	44.10	39.28
100000	33.70	33.90	34.00	40.10	41.20	37.00	43.90	43.70	44.90	39.16
150000	34.40	34.80	35.10	39.70	41.10	41.50	44.60	45.50	43.50	40.02
Mean	34.20	34.67	34.60	39.30	41.50	38.87	43.83	44.23	44.17	

Table 11: 데이터셋 크기와 미세조정 에폭 수가 평균 5-shot MMLU 시험 정확도에 미치는 효과. 데이터셋 크기를 늘리고 1 에폭 이상 학습하는 것이 MMLU 성능에 도움이 되지만, 데이터셋 간의 차이가 훨씬 크다. 이는 데이터셋 품질이 크기보다 MMLU 성능에 더 큰 영향을 준다는 것을 나타낸다.

부록 C. 인간 평가 (Human Evaluation)

원래의 Vicuna 평가에서 GPT-4에 주어진 것과 동일한 문구로 인간 평가를 수행하되, Figure 5와 같이 Amazon Mechanical Turk 양식에 맞게 조정했다.

Task

We would like to request your feedback on the performance of two AI assistants in response to the user question displayed below.

Please rate the helpfulness, relevance, accuracy, level of details of their responses. Each assistant receives an overall score on a scale of 1 to 10, where a higher score indicates better overall performance.

Please first rate each response out of 10.

Next, please provide a comprehensive explanation of your evaluation, avoiding any potential bias and ensuring that the order in which the responses were presented does not affect your judgment.

User Question

Imagine you are a time traveler from the year 3000. What technological advancements would you tell people about?

Response A

As an AI assistant, I don't have personal experiences or opinions. But I can tell you about some of the possible technological advancements that might exist in the year 3000 based on current trends and research. - Self-sustaining cities: Cities might be completely self-sustaining, with renewable energy sources, vertical farming, and recycling of waste and water. ...

Rating for Response A

- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9
- ☐ 10

Response B

As a time traveler from the year 3000, I would tell people about the following technological advancements: 1. Advanced Artificial Intelligence: In the future, AI is so advanced that it can completely automate many jobs that humans currently do. This has resulted in increased productivity and efficiency across many industries. ...

Rating for Response B

- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9
- ☐ 10

Comprehensive Explanation of Your Evaluation

Response X was better because...

Submit

Figure 5: 인간 주석자들이 사용한 클라우드소싱 양식.

부록 D. GPT-4를 이용한 쌍대 평가 (Pairwise Evaluation with GPT-4)

GPT-4 평가는 어느 시스템이 먼저 제시되었는가에 따라 다른 결과를 냈지만, 두 순서에 대해 평균하면 쌍대 결과는 잘 정렬되었다. 집계된 쌍대 판단은 Table 12에 있다. 검토해 보면 이 판단들은 이행적(transitive)임이 분명하다. 즉 시스템 A가 시스템 B보다 낫다고 판정되고 시스템 B가 시스템 C보다 낫다고 판정되면, 항상 시스템 A가 시스템 C보다 낫다고 판정된다. 이는 Table 13에 주어진 완전한 순서(complete ordering)를 낳는다.

Model	Guanaco 65B	Guanaco 33B	Vicuna	ChatGPT-3.5 Turbo	Bard	Guanaco 13B	Guanaco 7B
Guanaco 65B	-	0.21	0.19	0.16	0.72	0.59	0.86
Guanaco 33B	-0.21	-	0.17	0.10	0.51	0.41	0.68
Vicuna	-0.19	-0.17	-	0.10	0.50	0.20	0.57
ChatGPT-3.5 Turbo	-0.16	-0.10	-0.10	-	0.35	0.19	0.40
Bard	-0.72	-0.51	-0.50	-0.35	-	0.12	0.03
Guanaco 13B	-0.59	-0.41	-0.20	-0.19	-0.12	-	0.20
Guanaco 7B	-0.86	-0.68	-0.57	-0.40	-0.03	-0.20	-

Table 12: 시스템 간 집계된 쌍대 GPT-4 판단. 행 x , 열 y 셀의 값은 (x 가 y 보다 낫다는 판정 수 - y 가 x 보다 낫다는 판정 수) / 전체 판정 수 이다.

부록 E. NormalFloat 4비트 데이터 타입 (NormalFloat 4-bit data type)

NF4 데이터 타입의 정확한 값은 다음과 같다:

`[-1.0, -0.6961928009986877, -0.5250730514526367, -0.39491748809814453, -0.28444138169288635, -0.18477343022823334, -0.09105003625154495, 0.0, 0.07958029955625534, 0.16093020141124725, 0.24611230194568634, 0.33791524171829224, 0.44070982933044434, 0.5626170039176941, 0.7229568362236023, 1.0]`

부록 F. 학습된 신경망 가중치의 정규성 (Normality of Trained Neural Network Weights)

학습된 신경망 가중치가 대체로 정규분포를 따른다는 것은 상식이지만, 이를 검증하기 위해 통계적 검정을 수행한다. 7B LLaMA 모델의 가중치에 Shapiro-Wilk 검정을 적용한다. 각 은닉 유닛(hidden unit)의 가중치가 서로 다른 정규분포를 갖는다는 것을 발견했다. 그래서 각 은닉 유닛별로 가중치를 검정한다. 즉 가중치 $W \in \mathbb{R}^{in \times out}$ 에 대해 out 차원에 걸쳐 검정을 수행한다. 5% 유의 수준에서 뉴런의 7.5%가 비정규 분포를 따르는데, 이는 기대되는 위양성률보다 약 2.5% 많다. 따라서 거의 모든 사전학습 가중치가 정규분포를 따르는 것으로 보이지만 예외도 있는 듯하다. 그러한 예외는 이상치 가중치 때문이거나, LLaMA FFN 계층 은닉 유닛에서 발생하는 큰 표본 크기에 대해 Shapiro-Wilk 검정의 p -값이 정확하지 않기 때문일 수 있다.

부록 G. 메모리 사용량 (Memory Footprint)

서로 다른 LLaMA 기반 모델에 대한 QLoRA 학습의 메모리 사용량은 Figure 6에서 볼 수 있다. 33B 모델은 24GB에 온전히 들어가지 않아 학습하려면 페이지드 옵티마이저가 필요함을 볼 수 있다. 그림은 배치 크기 1, 시퀀스 길이 512, 그래디언트 체크포인트링 조건이다. 즉 더 큰 배치 크기를 쓰거나 긴 시퀀스를 처리하면 활성값 그래디언트가 상당한 메모리를 소비할 수 있다.




Figure 6: 서로 다른 LLaMA 모델의 메모리 사용량 내역. 입력 그래디언트 크기는 배치 크기 1, 시퀀스 길이 512 기준이며 어댑터와 기반 모델 가중치에 대해서만(어텐션 제외) 추정한 것이다. 막대 위의 숫자는 전체 사용량을 이루는 개별 요소의 메모리 사용량(MB)이다. 일부 모델은 특정 GPU에 완전히 들어가지 않지만, 페이지드 옵티마이저가 이 모델들을 들어가게 할 만큼의 메모리를 제공한다.

Model	Params	Size
Guanaco	65B	41 GB
Guanaco	33B	21 GB
Vicuna	13B	26 GB
ChatGPT-3.5 Turbo	N/A	N/A
Bard	N/A	N/A
Guanaco	13B	10 GB
Guanaco	7B	5 GB

Table 13: 시스템 간 쌍대 GPT-4 판단이 유도한 완전한 순서.